

WSI ćwiczenie 4 - Klasyfikacja

Natasza Jarecka

2025

1 Opis algorytmu

Las losowy, to metoda uczenia maszynowego stosowana do klasyfikacji i regresji, polegająca na budowaniu wielu losowych drzew decydujących o wyniku klasyfikacji.

Opis budowy drzewa:

- Utwórz węzeł-korzeń i dodaj go do kolejki węzłów.
- Dopóki kolejka węzłów nie jest pusta:
 - Weź węzeł z kolejki i go z niej usuń.
 - Jeżeli kryterium stopu jest spełnione, oznacz węzeł jako liść i wybierz dla niego klasę.
 - W przeciwnym przypadku wybierz losowo podzbiór atrybutów.
 - Wybierz podział na podstawie wybranych atrybutów.
 - Dla każdej gałęzi utwórz nowy węzeł i przypisz do niego część danych.
 - Dodaj węzeł do kolejki.
- Zwróć korzeń drzewa.

Opis lasu losowego:

- Wylosuj próbkę bootstrapową.
- Zbuduj randomizowane drzewo.
- Odczytaj predykcję dla wybranych wartości atrybutów.
- Powtórz zadaną ilość razy.
- Wybierz najczęściej przewidywaną klasę.

2 Opis danych

Dane wykorzystywane w ćwiczeniu dotyczą chorób serca. Występują następujące atrybuty:

- Sex
- ChestPainType
- FastingBS

- RestingECG
- ExerciseAngina
- ST_Slope
- AgeGroup
- RestingBP_Category
- Cholesterol_Category
- MaxHR_Category
- Oldpeak_Category

Wartością przewidywaną będzie kolumna HeartDisease.


Zbiór danych dzielę na zbiór treningowy i testowy. Pierwszy z nich stanowi 70% całego datasetu, a drugi 30%.

3 Eksperymenty i wyniki

W ramach eksperymentu sprawdziłam jakie wartości mają metryki dokładności, precyzji i czułości oraz pola pod krzywą ROC. Wyniki wyglądają następująco:

Liczba drzew	Accuracy	Precision	Recall	AUC
50	74%	64%	90%	0.85
100	80%	70%	95%	0.87
150	74%	64%	90%	0.88
200	70%	61%	86%	0.86
300	78%	68%	95%	0.84

Wyniki dla różnej ilości drzew



Krzywa ROC dla liczby drzew = 100

Liczba drzew	Accuracy	Precision	Recall	AUC
50	88%	86%	92%	0.94
100	89%	88%	93%	0.94
150	89%	88%	93%	0.94

Wyniki dla Scikit-learn

4 Wnioski

Gdyby model ten był faktycznie używany w służbie zdrowia, powinna zostać maksymalizowana metryka recall. Jeżeli chodzi o choroby, lepiej uznać za chorą osobę zdrową, niż przeoczyć faktycznie chorą osobę.

Im większa ilość drzew, tym lepsze powinny być predykcje modelu. Wynik jest wtedy mniej "losowy" i drzewa lepiej kompensują swoje błędy. Aczkolwiek, napisany przeze mnie algorytm nie zachowuje się do końca w ten sposób, czasem przy większej ilości drzew trafiają się gorsze wyniki. W porównaniu do Scikit Learn wypada gorzej o około 20 pp. Możliwe, że w implementacji pojawił się gdzieś błąd.